

README :

1) Instructions pour répliquer les résultats

Pour reproduire les résultats, il est important d'exécuter les notebooks dans l'ordre indiqué dans leurs titres. Avant de les exécuter, **il faut lire attentivement les notebooks 9 et 10, que j'ai déjà exécutés sur Kaggle**, car ils utilisent un LLM pour la génération. Il y a quelques manipulations spécifiques à respecter :

- Télécharger correctement les fichiers CSV d'entrée dans Kaggle.
- La génération de résumés étant chronophage, le Notebook 9 a été exécuté en plusieurs fois pour annoter quelques lignes de mon CSV. Les manipulations à faire pour exécuter le notebook en plusieurs fois sont détaillées dedans.

Une fois les notebooks exécutés, il faut créer une base de données avec PostgreSQL et y mettre les données `procedures_2025.csv`, puis la lier avec Flask dans le fichier `app.py`, qui crée le site. Si on exécute `app.py` dans le terminal (en lançant la commande `flask run`), on peut ouvrir le site en local. Pour la publication, j'ai rendu le site totalement statique avec le fichier `freeze_website.py` (le rendre statique le rends gratuit à la publication avec Github, puisqu'on n'a pas besoin de passer par Render).

2) Quel fichier correspond à quoi ?

Dossier docs : comprend les fichiers utilisés par Github pour publier mon site

Dossier static : comprend les fichiers permettant le style de mon site (js, css, images)

Dossier templates : contient les codes pour les pages html de mon site

Notebooks (les flèches indiquent quels CSV sont produits par l'exécution du Notebook) :

1_url_scraper : scrape les urls des procédures législatives répertoriées dans l'Observatoire législatif.

- list_urls_2025.csv

2_scraper : scrape les informations directement disponibles sur une page décrivant une procédure législative ordinaire

- urls_not_found_2025.csv
- urls_no_title_2025.csv
- urls_missing_title_span_2025.csv
- final_scrape_2025.csv

3_data_manip_technical_info : manipulation de données sur la colonne `technical_info` pour en extraire les données et les stocker dans de nouvelles variables

- final_sample_cod_manip_2025.csv

4_legislative_proposal_scraper : scrape les textes des propositions législatives

- lp_url_not_found_2025.csv
- final_sample_cod_legislative_scrape_2025.csv

5_lp_scraped_verifier : identifie quelles procédures n'ont pas permis de scraper le texte de la proposition législative

6_text_adopted_scraper : scrape les textes adoptés des procédures terminées

- final_sample_cod_TA_2025.csv

7_final_act_scraper : scrape les actes finaux des procédures terminées

- final_sample_cod_TA_final_act_2025.csv

8_splitting_datasets : sépare la base de données en 4 bases de données qui regroupent chacune les procédures relevant d'une de ces catégories : procédures complétées, procédures rejetées, procédures en cours, procédures abandonnées ou retirées

- sample_cod_completed_2025.csv
- sample_cod_rejected_2025.csv
- sample_cod_lapsed_2025.csv
- sample_cod_ongoing_2025.csv

9_summarization_proposals : résume quelques propositions législatives d'avril à décembre 2025

- cod_completed_proposal_general_summary_0_5.csv
- cod_completed_proposal_general_summary_5_10.csv
- cod_completed_proposal_general_summary_10_15.csv
- cod_completed_proposal_general_summary_15_17.csv
- cod_proposal_general_summary_0_5.csv
- cod_proposal_general_summary_5_10.csv
- cod_proposal_general_summary_10_20.csv
- cod_completed_proposal_general_summary_20_25.csv

10_summarization_final_acts : résume les actes finaux adoptés par le Parlement Européen en 2025

- cod_final_act_general_summary.csv

11_final_manipulation_for_sql : agrège les procédures en cours et complétées et les nettoie pour les importer sur PostgreSQL

- completed_proc_clean_2025.csv
- ongoing_proc_clean_2025.csv
- procedures_2025.csv

